

# 刘尚昊

somehow6@outlook.com | +86 177-7313-3127

## 教育经历



计算机科学博士  
新加坡国立大学 计算机学院

预计 2026 年 8 月入学  
新加坡

- 导师: Wenqi Jiang 教授



计算机科学硕士  
北京航空航天大学 计算机学院

2023 - 预计 2026 年 6 月  
北京

- 导师: 杨海龙 教授 | GPA: 3.52/4.00 | IELTS: 6.5
- 论文: 面向视频生成的稀疏注意力性能优化
- 奖项: 一等奖学金 (2023)



物理学学士  
兰州大学 物理科学与技术学院

2019 - 2023  
兰州

- 论文: 基于神经架构搜索的双星引力波探测优化 (优秀毕业论文)
- GPA: 89.29/100
- 奖项: 一等奖学金 (2021)、二等奖学金 (2020、2022)、华为鲲鹏奖学金 (2021)

## 学术成果

- Liu, S.; Chen, R.; Zheng, S.; Liu, Y.; Liang, Y. (Eric); Yang, H. SPADE: An Input-Adaptive Sparse Attention Engine for Fast Video Diffusion Models Inference. In *Proceedings of the the Chips to Systems Conference DAC 2026*; DAC '26; Association for Computing Machinery: New York, NY, USA, 2026.
- Liu, S.; Yang, H.; You, X.; Luan, Z.; Liu, Y.; Qian, D. Efficient Locality-Aware Instruction Stream Scheduling for Stencil Computation on ARM Processors. In *Proceedings of the 39th ACM International Conference on Supercomputing*; ICS '25; Association for Computing Machinery: 2025; pp 250–264. <https://doi.org/10.1145/3721145.3725760>.
- Liu, X.; Yang, X.; Ma, K.; Liu, S.; Zhang, K.; Yang, H.; Liu, Y.; Luan, Z.; Qian, D. Moirae: Generating High-Performance Composite Stencil Programs with Global Optimizations. In *Proceedings of the International Conference for High Performance Computing, Networking, Storage, and Analysis*; SC '24; IEEE Press: Atlanta, GA, USA, 2024. <https://doi.org/10.1109/SC41406.2024.00026>.

## 科研经历

面向视频扩散模型的高性能稀疏 vDiT 引擎 (DAC 2026)

2025 年 4 月 - 2025 年 11 月

北航 & 字节跳动 SEED AI RESEARCH

北京

- 一作,设计 vDiT-SSR 统一块稀疏注意力表示,融合静态、半静态与动态 3D 块模式,适配视频扩散 Transformer。
- 基于 vDiT-SSR 构建免训练稀疏注意力引擎 SPADE,通过 SICS 驱动的头级策略为每个输入生成稀疏方案,并编译为 Flash 风格块稀疏 CUDA/Triton 内核,包含低开销索引检索、算子融合与分组启动。
- 在 Hunyuan-Video 与 Wan 2.1/2.2 文生视频、图生视频任务上,生成质量持平或更优;注意力计算加速 2.26x-3.40x,端到端吞吐提升 1.49x-1.80x,优于已有 SOTA 稀疏注意力方法。

C/C++ CUDA C/C++ Triton Python

面向 ARM 的 Stencil 算子编译优化与指令流调度 (ICS 2025)

2024 年 5 月 - 2024 年 10 月

北航中德软件研究所实验室

北京

- 一作;源码: [AOSTencil Repo](#)
- 提出 SFTBR (Serial-FMA to Tree-Based Reduction) 方法,用于指令重排与指令级并行优化。
- 设计利用 L3 缓存、ccNUMA 与多路内存层次的局部性调度模型。
- 在类 TVM 的领域专用编译器中集成 SIMD、分块与循环展开优化。
- 通过遗传算法驱动的调参与调度,在 ARM 平台上相对现有 Stencil 编译器最高实现 4.39x 加速。

Python C/C++ ARM NEON

面向 GPU 的全局优化 Stencil 编译 (SC 2024)

2023 年 9 月 - 2024 年 4 月

北航中德软件研究所实验室

北京

- 构建基于数据搬运的成本模型,用于预测 GPU 内存访问模式。
- 实现 Stencil 算子的横向 (分支) 与纵向 (顺序) 融合优化。
- 设计由成本模型引导的计算图融合进化搜索算法。

- 相对 Open Earth 与 Artemis 基线分别实现 2.6x 与 1.8x 加速。

Python CUDA C/C++

## 实习经历

机器学习推理优化工程师

2025 年 2 月 - 至今

字节跳动 SEED AI INFRASTRUCTURE 团队

北京

- 面向 NPU 的高性能 Triton 内核与编译器支持
- 面向 LLM 场景的 ByteIR 开发与优化

C/C++ MLIR Triton Python

## 项目经历

面向 NPU 的高性能 Triton 内核与编译器

2025 年 3 月 - 至今

字节跳动 SEED AI INFRASTRUCTURE

北京

- 在构建 LLM 算子库过程中定位并修复 Triton 编译器缺陷，提升编译稳定性与可维护性。
- 针对自研加速器架构设计高性能 Triton 算子实现。
- 通过处理器单元专用化、异步数据搬运与计算-IO 重叠优化 LLM 算子 NPU 内核，相比上一版本实现 2x 加速。

C++ MLIR Triton Python

ByteIR 在 LLM 场景的开发与优化

2025 年 5 月 - 2025 年 8 月

字节跳动 SEED AI INFRASTRUCTURE

北京

- 在 BYTEIR 中新增面向 LLM 的特性并优化 GPU 性能。
- 设计并开发 ByteIR 新后端模块 Triton-Backend，支持高效灵活的算子编译。

C++ MLIR Triton Python

面向 RISC-V 向量扩展的动态张量程序编译优化

2024 年 6 月 - 2024 年 10 月

开源之夏 - BUDDY-COMPILER

北京

- 基于 MLIR 多级 IR 与 Buddy Compiler 后端实现 RISC-V 优化策略。
- 优化 BatchMatmul、conv2d-nhwc-fhwc、depthwise-nhwc-hwc 等算子。
- 通过优化访存模式、向量化、分块策略与 RISC-V 向量指令利用，相比原生 MLIR 达到 12x 加速，相比原始 Buddy-compiler 达到 2x 加速。
- 利用 RISC-V 硬件特性，包括标量-向量广播 FMA 与运行时可配置向量寄存器长度。
- 将优化集成到 TinyLlama 与 MobileNetV3，在 RISC-V 平台最高实现 25% 加速。
- 相关优化已通过 PR 合并：Buddy-mlir、Buddy-benchmark。

MLIR C++

仿真软件 ARM 处理器优化

2023 年 3 月 - 2023 年 9 月

北航中德软件研究所实验室

北京

- 针对飞腾 S2500 ARM CPU 优化稀疏矩阵与卷积计算。
- 设计利用缓存层次的多级稀疏访存结构。
- 在飞腾 S2500 上相对 ArmPL、Kokkos、Halide 基线实现 20% 性能提升。

C/C++ OpenMP ARM NEON Python

华为鲲鹏 ARM 迁移与优化

2021 年 8 月 - 2021 年 11 月

兰州大学

兰州

- 面向鲲鹏 ARM 架构完成 GROMACS 与 LAMMPS 的迁移与优化。
- 完成性能剖析与调优，实现约 10% 性能提升。

Linux C/C++ MPI OpenMP

## 奖项与荣誉

- |             |                                             |
|-------------|---------------------------------------------|
| 2022 年 9 月  | 全国大学生创新创业大赛, 三等奖                            |
| 2022 年 3 月  | ASC 2022 世界大学生超级计算机竞赛总决赛 (队长), 全球第 6 / 300+ |
| 2021 年 4 月  | 全国编程能力等级大赛 (天梯赛) 总决赛, 三等奖                   |
| 2020 年 10 月 | ICPC 西北区域赛, 银牌                              |

## 技能

技术栈 C/C++ | CUDA | Python | MLIR  
英语 IELTS 6.5